



NAÏVE BAYES



La estimación de la probabilidad de un evento, o un resultado potencial, debe basarse en la evidencia dada por múltiples ensayos u oportunidades para que ocurra el evento



Los métodos bayesianos proporcionan información sobre cómo la probabilidad de estos eventos puede ser estimada a partir de los datos observados



Los principios básicos de probabilidad se usan transversalmente en el algoritmo **Naïve Bayes**

PROBABILIDAD BAYESIANA



CLASIFICADORES BAYESIANOS

- Los clasificadores bayesianos asignan cada observación a la clase j más probable, dados los valores observados de sus variables predictivas:

$$\operatorname{argmax}_j p(Y = y_j | X = x_{\text{observados}})$$

- Si se conocen las distribuciones de probabilidad, el clasificador resultante da la frontera de separación óptima en términos de error
- No siempre se tienen las probabilidades condicionales necesarias.
- **Naïve Bayes** es un algoritmo basado en el Teorema de Bayes

- Algunas aplicaciones de los clasificadores Bayesianos son:

- Clasificación de texto, como el filtrado de correo no deseado (spam)
- Detección de intrusiones o anomalías en redes informáticas.
- Diagnóstico de afecciones médicas debido a un conjunto de síntomas observados.
- Funcionan muy bien en problemas en los que la información de numerosos atributos deben considerarse simultáneamente para estimar la probabilidad general de un resultado

X_2



NAIVE BAYES (BAYES INGENUO)

Teorema de Bayes:
$$p(y_j | x_1, x_2, \dots, x_n) = \frac{p(y_j, x_1, x_2, \dots, x_n)}{p(x_1, x_2, \dots, x_n)} = \frac{p(y_j) * p(x_1, x_2, \dots, x_n | y_j)}{p(x_1, x_2, \dots, x_n)}$$

El denominador es solo usado para propósitos de normalización (suma de probabilidades = 1)

$$p(x_1, x_2, \dots, x_n) = \sum_j p(y_j) * p(x_1, x_2, \dots, x_n | y_j)$$

- Por ello solo nos fijamos en el numerador:

$$p(y_j, x_1, x_2, \dots, x_n) = p(y_j) * p(x_1 | y_j) * p(x_2 | x_1, y_j) * p(x_3 | x_2, x_1, y_j) * \dots * p(x_n | x_{1:n-1}, y_j)$$

- Si asumimos ingenuamente (**naïvely**) que todas las variables predictivas x_i son independientes condicionalmente con respecto a la clase y_j ¹ entonces el numerador se simplifica a:

$$\begin{aligned} p(y_j) * p(x_1 | y_j) * p(x_2 | y_j) * p(x_3 | y_j) * \dots * p(x_n | y_j) \\ = p(y_j) \prod_{i=1}^n p(x_i | y_j) \end{aligned}$$



NAÏVE BAYES (BAYES INGENUO)

- La regla de clasificación es:

$$\operatorname{argmax}_j p(y_j) \prod_{i=1}^n p(x_i|y_j)$$

- **Sólo necesitamos especificar :**

- Las probabilidades a priori de cada clase

- Las distribuciones de probabilidad de las variables predictivas para cada clase (condicionadas a la clase)

- Esta información se constituye en los **parámetros** del modelo, y en el caso de variables categóricas se obtienen a partir de tablas de frecuencias (conteos)



NAIVE BAYES

Ejemplo: Un banco quiere predecir si un cliente va a adquirir un CDT.

Creamos un clasificador Naïve Baye a partir de los datos históricos para calcular las probabilidades posteriores de cada clase: subscribed=yes and subscribed=no.

¿Debería el banco ofrecerle un CDT al cliente con la información siguiente?

$$p(y_j | x_1, \dots, x_n) = \underset{j}{\operatorname{argmax}} p(y_j) \prod_{i=1}^n p(x_i | y_j)$$

Diagram illustrating the Naive Bayes formula and associated data tables. The formula shows the joint probability of a class y_j and features x_1, \dots, x_n . The feature x_i is highlighted in blue, and the class y_j is highlighted in yellow. The data tables below provide the conditional probabilities for the 'Marital' feature.

Marital	Subscribed=yes	Subscribed=no
Single	35%	28%
Married	53%	61%
Divorced	12%	11%

Subscribed=yes	Subscribed=no
12%	88%

Job=Management
 Marital=Married
 Education=Secondary
 Default=no
 Housing=yes
 Loan=no
 Contact=Cellular
 Outcome=Success

Suponga que se disponen de las probabilidades condicionales para todas las variables predictivas (ya ilustradas para el estado civil “Marital”)



NAIVE BAYES

Ejemplo: Un banco quiere predecir si un cliente va a adquirir un CDT.

Creamos un clasificador Naïve Bayes a partir de los datos históricos para calcular las probabilidades posteriores para cada clase: subscribed=yes and subscribed=no.

$$p(y_j | x_1, \dots, x_n) = \underset{j}{\operatorname{argmax}} p(y_j) \prod_{i=1}^n p(x_i | y_j)$$

Marital	Subscribed=yes
Single	35%
Married	53%
Divorced	12%

Marital	Subscribed=no
Single	28%
Married	61%
Divorced	11%

Subscribed=yes	12%
----------------	-----

Subscribed=no	88%
---------------	-----

¿Debería el banco ofrecerle un CDT al cliente con la información siguiente?

	Subscribed=yes	Subscribed=no
Job=Management	22%	21%
Marital=Married	53%	61%
Education=Secondary	46%	51%
Default=no	99%	98%
Housing=yes	35%	57%
Loan=no	90%	85%
Contact=Cellular	85%	62%
Outcome=Success	15%	1%
Priors	12%	88%
Numerador	0,000255914	0,000169244
Proba posterior	60%	40%



NAÏVE BAYES (BAYES INGENUO)

- ¿Qué pasa si algunos de los valores de las variables predictivas tienen frecuencia nula con respecto a las categorías de la clase? ¿cuáles serían sus probabilidades a posteriori asociadas?
- Para evitar este problema, se utilizan métodos de **suavización**.
 - Por ejemplo, al contar las frecuencias de ocurrencia de cada valor se les agrega un valor pequeño, $\varepsilon > 0$, evitando que alguna probabilidad sea cero:

$$P(\text{casado}|\text{cliente potencial}) = \frac{\text{Conteo}(\text{casado, cliente potencial}) + \varepsilon}{\text{Conteo}(\text{cliente potencial}) + N(x) * \varepsilon}$$

- El método de suavización de **Laplace** se aplica usualmente con $\varepsilon=1$, otro valor puede ser $1/n$ donde n es el número de datos de entrenamiento.



NAÏVE BAYES (BAYES INGENUO)

- Cuando las variables predictivas no son categóricas (e.g. numéricas), es necesario establecer una distribución de probabilidad:
 1. Se puede discretizar (en compartimentos) la variable convirtiéndola en categórica.
 2. Se establece una distribución de probabilidad empírica utilizando KNN,

$$P(Y = j|X = x_0) = \frac{1}{k} \sum_{i \in \mathbb{N}_0} I(y_i = j)$$

3. Se supone que se trata de un tipo de distribución de probabilidad y se utiliza su función de densidad.
 - Por ejemplo, si se supone la variable sigue una **distribución normal** condicionada a la categoría objetivo, se puede calcular la media μ y desviación estándar σ a partir de los datos históricos, y utilizar la función de densidad:

$$P(\text{edad}|\text{cliente potencial}) = \frac{1}{\sigma_{\text{edad}|\text{cliente}} \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{\text{edad} - \mu_{\text{edad}|\text{cliente}}}{\sigma_{\text{edad}|\text{cliente}}} \right)^2}$$



NAÏVE BAYES (BAYES INGENUO)

Pros:

- **Simple, rápido** y muy **efectivo**, permite atributos tanto categóricos como numéricos
- Estima efectivamente **las probabilidades condicionales** con respecto a los valores de la categoría objetivo
- Trabaja bien con atributos categóricos, con **valores faltantes** y con ruido
- Resistente al **overfitting**, sobretodo si se incluye un suavizador (e.g. Laplace)
- Trabaja bien con muestras de entrenamiento pequeñas y también con grandes

Contras:

- Sólo se puede utilizar para **clasificación**
- Se basa en **suposiciones** muy fuertes
- **Muy sensible** a atributos correlacionados (considera varias veces los mismos efectos)
- Las probabilidades estimadas son menos confiables que las clases predichas

